


Mission

L'entreprise **GreenAndCoop**, fournisseur d'électricité d'origine renouvelable, souhaite gagner en précision dans les prévisions pour équilibrer le réseau, optimiser la production et maîtriser ses coûts.

L'objectif du projet **Forecast 2.0** de celui-ci est d'intégrer de nouvelles sources de données dans leurs algorithmes comme celles issues de stations météorologiques semi-professionnelles.

La mission consiste à **concevoir, implémenter et industrialiser un pipeline de données de type ELT** permettant d'ingérer, transformer et fiabiliser ces nouvelles données météorologiques. Les données proviennent de différents réseaux (open data, stations InfoClimat, stations Weather Underground, etc.).

Pipeline local



Configuration Airbyte

Source

 **infoclimat_observations_raw_file**
File (CSV, JSON, Excel, Feather, Parquet) v0.6.0

SettingsConnections

Source Settings

Source name ⓘ
infoclimat_observations_raw_file

Dataset Name ⓘ
infoclimat_observations_raw

File Format ⓘ
csv

Storage Provider ⓘ
HTTPS: Public Web

> Optional fields

URL ⓘ
https://oc-projet8-temp-697908643602-eu-west-3-an.s3.eu-west-3.amazonaws.com/infoclimat

Destination

 **Postgres_weather**
Postgres v3.0.11

SettingsConnections

Destination Settings

Destination name ⓘ
Postgres_weather

Connection

Host ⓘ
host.docker.internal

Port ⓘ
5432

Database Name ⓘ
weather_db

Default Schema ⓘ
staging

Username ⓘ
postgres

Connexion

 **infoclimat_observations_raw_file → Postgres_weather**
 infoclimat_observations_raw_file →  Postgres_weather

StatusTimelineSchemaMappingsSettings

Settings

Connection name
Name for your connection
infoclimat_observations_raw_file → Postgres_

Tags
+

Schedule type
How you want your syncs to be triggered
Manual

Ingestion des fichiers source en tables raw



Nom	Type
infoclimat_observations_raw.csv	csv
infoclimat_stations_raw.csv	csv
weatherug_observations_raw_ichtegem_011024.csv	csv
weatherug_observations_raw_ichtegem_021024.csv	csv
weatherug_observations_raw_ichtegem_031024.csv	csv
weatherug_observations_raw_ichtegem_041024.csv	csv
weatherug_observations_raw_ichtegem_051024.csv	csv
weatherug_observations_raw_ichtegem_061024.csv	csv
weatherug_observations_raw_ichtegem_071024.csv	csv
weatherug_observations_raw_lamadeleine_011024.csv	csv
weatherug_observations_raw_lamadeleine_021024.csv	csv
weatherug_observations_raw_lamadeleine_031024.csv	csv
weatherug_observations_raw_lamadeleine_041024.csv	csv
weatherug_observations_raw_lamadeleine_051024.csv	csv
weatherug_observations_raw_lamadeleine_061024.csv	csv
weatherug_observations_raw_lamadeleine_071024.csv	csv
weatherug_stations_raw.csv	csv



Source

Format fichier: **csv**

Stockage: **HTTPS Public Web**

Destination


Schéma: **staging**



List of schemas	
Name	Owner
intermediate	postgres
marts	postgres
public	pg_database_owner
staging	postgres

List of relations	
Schema	Name
staging	infoclimat_observations_raw
staging	infoclimat_stations_raw
staging	weatherug_observations_raw_ichtegem_011024
staging	weatherug_observations_raw_ichtegem_021024
staging	weatherug_observations_raw_ichtegem_031024
staging	weatherug_observations_raw_ichtegem_041024
staging	weatherug_observations_raw_ichtegem_051024
staging	weatherug_observations_raw_ichtegem_061024
staging	weatherug_observations_raw_ichtegem_071024
staging	weatherug_observations_raw_lamadeleine_011024
staging	weatherug_observations_raw_lamadeleine_021024
staging	weatherug_observations_raw_lamadeleine_031024
staging	weatherug_observations_raw_lamadeleine_041024
staging	weatherug_observations_raw_lamadeleine_051024
staging	weatherug_observations_raw_lamadeleine_061024
staging	weatherug_observations_raw_lamadeleine_071024
staging	weatherug_stations_raw

Configuration projet BDT



Structure de dossiers

models/ (cœur du projet)

Chaque dossier staging, intermediate et marts contient:

- Les scripts SQL/Jinja exécutant les transformations.
- Optionnellement un fichier schema.yml qui décrit les tests.

Fichier sources.yml

macros/

Fonctions réutilisables (Jinja).

Exemple: generate_schema_name.sql

tests/

Tests personnalisés (SQL). Complètent les tests dans schema.yml par des tests métier spécifiques.

data/

Données annexes

dbt_packages/

Dépendances

target/

SQL compilé

Documentation JSON

docker_dbt/

Configuration spécifique Docker, dont profiles.yml embarqué.

Détail des fichiers

dbt_project.yml

Fichier principal. Décrit:

- La configuration projet
- Les chemins des modèles
- La matérialisation (vue, table, schéma)

packages.yml et **package-lock.yml**

Définition des dépendances dbt

Verrouillage les versions des packages

dockerfile

Build du conteneur dbt utilisé avec ECS / Fargate

README.md

Documentation projet

sources.yml

Déclaration des données sources (tables brutes raw)

profiles.yml

Connexion à la base de données

Modèle Staging

Schema	Name	Type
staging	infoclimat_stations_raw	table
staging	weatherug_stations_raw	table

Stations

Schema	Name	Type
staging	stg_infoclimat_stations	view
staging	stg_weatherug_stations	view

stg_infoclimat_stations.sql

- Ajustement et typage (**trim / cast**)
- Standardisation des noms de colonnes
- Création des colonnes 'hardware' & 'software' (harmonisation avec Weather Underground)

stg_weatherug_stations.sql

- Ajustement et typage (**trim / cast**)
- Standardisation des noms de colonnes
- Création des colonnes 'station_type' & 'license' (harmonisation avec Infoclimat)

Schema	Name	Type
staging	infoclimat_observations_raw	table
staging	weatherug_observations_raw_ichtegem_	table
staging	weatherug_observations_raw_lamadeleine_	table

Observations

Schema	Name	Type
staging	stg_infoclimat_observations	view
staging	stg_weatherug_observations	view

stg_infoclimat_observations.sql

- Typage des champs numériques (**cast**)
- Standardisation des noms de colonnes
- Création des colonnes 'precip_rate' & 'precip_accum' (harmonisation avec Weather Underground)
- Création de la colonne 'source_system' (origine Infoclimat)

stg_weatherug_observations.sql

- Conversion d'unités et typage (**regexp + cast / ratio**)
- Standardisation des noms de colonnes
- Création des colonnes 'precip_1h' & 'precip_3h' (harmonisation avec Infoclimat)
- Création de la colonne 'source_system' (origine Weather Underground)

Modèle Intermediate

Schema	Name	Type
staging	stg_infoclimat_stations	view
staging	stg_weatherug_stations	view

Stations

Schema	Name	Type
intermediate	int_weather_stations	view

int_weather_stations.sql

- Union des 2 modèles de stations
- harmonisation métier (license et software dans license_unified)
- Création de station_source

Schema	Name	Type
staging	stg_infoclimat_observations	view
staging	stg_weatherug_observations	view

Observations

Schema	Name	Type
intermediate	int_weather_observations	view

int_weather_observations.sql

- Union des 2 modèles d'observations
- Structure commune des mesures météo (sauf champs spécifiques pluie)

Modèle Marts

Schema	Name	Type
intermediate	int_weather_stations	view

Stations

Schema	Name	Type
marts	dim_weather_stations	table

dim_weather_stations.sql

- Dimension finale des stations
- Clé: station_id, indexation

Schema	Name	Type
intermediate	int_weather_observations	view

Observations

Schema	Name	Type
marts	fact_weather_observations	table

fact_weather_observations.sql

- table de faits finale
- Clé analytique : station_id + observed_at, indexation
- Indexation de station_id et observed_at

Structure Marts

1:n

Table "marts.fact_weather_observations"				
Column	Type	Collation	Nullable	Default
station_id	text			
observed_at	timestamp without time zone			
temperature	numeric			
humidity	numeric			
pressure	numeric			
dew_point	numeric			
wind_speed_avg	numeric			
wind_direction	numeric			
precip_1h	numeric			
precip_3h	numeric			
precip_rate	numeric			
precip_accum	numeric			
source_system	text			
Indexes:				
"0c7ae68b94257d71ce18771b48865318" btree (observed_at)				
"2a524605b69b5b7c44d1e92ff6b3dac5" btree (station_id)				
"ea85dc6bc4eb1e2dd99b16f39b06cbd4" UNIQUE, btree (station_id, observed_at)				

Table "marts.dim_weather_stations"				
Column	Type	Collation	Nullable	Default
station_id	text			
station_name	text			
station_source	text			
station_type	character varying			
latitude	numeric			
longitude	numeric			
elevation	numeric			
license_unified	character varying			
Indexes:				
"69f3be6cd09c19cdf4ce30838bd9879a" UNIQUE, btree (station_id)				

Qualité

Tests Staging

schema.yml

- not_null
- unique
- accepted_values
- accepted_range

Tests Marts

schema.yml


- not_null
- unique
- accepted values
- relationships fact -> dim

Documentation - Lineage

Stations



Observations



Indexation et performances

```
weather_db=# SET enable_indexscan = off;
SET enable_bitmapscan = off;
EXPLAIN ANALYZE
SELECT *
FROM marts.fact_weather_observations
WHERE station_id = 'IICHTE19'
AND observed_at >= '2024-10-01'
AND observed_at < '2024-10-02';
```

Performances sans index

QUERY PLAN

```
-----
Seq Scan on fact_weather_observations (cost=0.00..186.62 rows=220 width=117) (actual time=0.770..2.414 rows=288 loops=1)
  Filter: ((observed_at >= '2024-10-01 00:00:00'::timestamp without time zone) AND (observed_at < '2024-10-02 00:00:00'::timestamp without time zone) AND (station_id = 'IICHTE19'::text))
  Rows Removed by Filter: 4662
Planning Time: 1.389 ms
Execution Time: 2.542 ms
```

Sans index, PostgreSQL effectue un scan complet de la table, ce qui est inefficace.

Avec index, seules les pages nécessaires sont lues, ce qui réduit drastiquement le temps d'exécution.


```
weather_db=# SET enable_indexscan = on;
SET enable_bitmapscan = on;
EXPLAIN ANALYZE
SELECT *
FROM marts.fact_weather_observations
WHERE station_id = 'IICHTE19'
AND observed_at >= '2024-10-01'
AND observed_at < '2024-10-02';
```

Performances avec index

QUERY PLAN

```
-----
Bitmap Heap Scan on fact_weather_observations (cost=11.09..114.94 rows=220 width=117) (actual time=0.036..0.077 rows=288 loops=1)
  Recheck Cond: ((station_id = 'IICHTE19'::text) AND (observed_at >= '2024-10-01 00:00:00'::timestamp without time zone) AND (observed_at < '2024-10-02 00:00:00'::timestamp without time zone))
  Heap Blocks: exact=7
   -> Bitmap Index Scan on ea85dc6bc4eb1e2dd99b16f39b06cbd4 (cost=0.00..11.03 rows=220 width=0) (actual time=0.032..0.047 rows=288 loops=1)
        Index Cond: ((station_id = 'IICHTE19'::text) AND (observed_at >= '2024-10-01 00:00:00'::timestamp without time zone) AND (observed_at < '2024-10-02 00:00:00'::timestamp without time zone))
Planning Time: 0.132 ms
Execution Time: 0.100 ms
```


Pipeline AWS



Amazon EC2 – Airbyte

☰

EC2 > Instances > i-0b0869d022dc0d342

EC2

Tableau de bord

AWS Global View

Événements

▼ Instances

Instances

Types d'instances

Modèles de lancement

Demandes Spot

Savings Plans

Instances réservées

Hôtes dédiés

Réservations de capacité

Capacity Manager

▼ Images

AMI

Catalogue des AMI

Résumé de l'instance pour i-0b0869d022dc0d342 (oc-projet8-airbyte)

Mis à jour il y a less than a minute

ID d'instance

i-0b0869d022dc0d342

Adresse IPv6

-

Type de nom d'hôte

Nom de l'adresse IP: ip-172-31-38-76.eu-west-3.compute.internal

Réponse à un nom DNS de ressource privée

IPv4 (A)

Adresse IP attribuée automatiquement

13.38.61.104 [IP publique]

Rôle IAM

-

Adresse IPv4 publique

13.38.61.104 | adresse ouverte

État de l'instance

En cours d'exécution

Nom DNS de l'IP privé (IPv4 uniquement)

ip-172-31-38-76.eu-west-3.compute.internal

Type d'instance

m7i-flex.large

Adresses IPv4 privées

172.31.38.76

DNS public

ec2-13-38-61-104.eu-west-3.compute.amazonaws.com | adresse ouverte

Adresses IP élastiques

-

▼ Règles entrantes

Filter les règles

Nom	ID de règle du groupe de s...	Plage de ports	Protocole	Source
-	sgr-00841a80b73c02b00	8000	TCP	0.0.0.0/0
-	sgr-00336ba61adb31b08	8001	TCP	0.0.0.0/0
-	sgr-0284b4123f9c19085	22	TCP	0.0.0.0/0

Type d'instance

Éligible ...

vCPU

Architecture

Mémoire (Gio)

m7i-flex.large

vrai

2

x86_64

8

Infrastructure EC2

- Accès via SSH (installation et administration)
- Configuration du Security Group :
Port 22 > accès SSH
Port 8000 > interface Airbyte
Port 8001 > API Airbyte

Instance EC2

- m7i-flex.large :
CPU = 2
Architecture = x86_64
Mémoire = 8 Go

Installation d'Airbyte

- Installation via abctl
- Déploiement d'Airbyte par conteneurs Docker (via Kubernetes local "kind")

Amazon RDS – Postgres

Aurora and RDS

Tableau de bord

Bases de données

Analyse des performances

Instantanés

Exporte dans Amazon S3

Sauvegardes automatiques

Instances réservées

Proxys

Groupes de sous-réseaux

Groupes de paramètres

Groupes d'options

Versions de moteur personnalisées

Intégrations Zero-ETL

Événements

Abonnements aux événements

oc-projet8-db

Modifier

Actions

Récapitulatif

Identifiant de base de données
oc-projet8-db

Processeur
 3.96%

Statut
✓ Disponible

Classe
db.t4g.micro

Rôle
Instance

Activité actuelle
 0.02 séances

Moteur
PostgreSQL

Région et AZ
eu-west-3c

Recommandations
■ 2 Informatif

<

Connectivité et sécurité

Surveillance

Journaux et événements

Configuration

Intégrations Zero-ETL

Maintenance et sauvegardes

Migratio

>

Instance

Configuration

Classe d'instance

Stockage principal

Surveillance

ID d'instance de base de données
oc-projet8-db

Version du moteur
17.6

Support étendu RDS
Désactivé

Classe d'instance
db.t4g.micro

vCPU
2

RAM
1 Go

Groupe de sécurité	Type	Règle
oc-projet8-db-sg (sg-0c3853170c70a2e40)	CIDR/IP - Inbound	0.0.0.0/0
oc-projet8-db-sg (sg-0c3853170c70a2e40)	EC2 Security Group - Inbound	sg-0629f7428779680ab
oc-projet8-db-sg (sg-0c3853170c70a2e40)	CIDR/IP - Outbound	0.0.0.0/0

Définition du service

- Moteur : PostgreSQL
- Stockage = 20 Go
- Règles des groupes de sécurité

Classe

- db.t4g.micro :
- CPU = 2
- Mémoire = 1 Go

Amazon ECR – Image DBT

Amazon ECR

Registre privé

Référentiels

dbt-projet8

Amazon Elastic Container Service

Registre privé

Référentiels

dbt-projet8

Caractéristiques et paramètres

Registre public

Référentiels

Paramètres

Galerie publique de l'ECR

Amazon ECS

Amazon EKS

Démarrage

Documentation

dbt-projet8

RésuméImagesStratégie de cycle de vieAutorisationsBalises du référentiel

Détails du référentiel

Nom du référentiel

dbt-projet8

Créé à

07 avril 2026, 16:02:12 (UTC+02)

ARN du référentiel

arn:aws:ecr:eu-west-3:697908643602:repository/dbt-projet8

URI du référentiel

697908643602.dkr.ecr.eu-west-3.amazonaws.com/dbt-projet8

Mutabilité de la balise

Mutable

Exclusions de mutabilité de la balise

-

Type de chiffrement

AES-256

Fréquence d'analyse

Manuel

Configuration

Stratégie de cycle de vie

Aucune stratégie de cycle de vie

Autorisations

Aucune politique d'autorisation du référentiel

AWS balises

Aucune balise de référentiel

Définition du conteneur dockerfile

- Image basée sur Python 3.12 slim (légère et rapide)
- Installation de dbt + adapter PostgreSQL
- Intégration du projet dbt (modèles, tests, macros)
- Configuration via profiles.yml (connexion base de données)

Amazon ECS + Fargate – Exécution DBT

Amazon Elastic Container Service

Mode Express

Clusters

Espaces de noms

Définitions de tâches

Définitions de tâche de démon

Nouveau

Paramètres du compte

AWS Batch

Amazon ECR

Référentiels

Atelier d'apprentissage en ligne

Documentation

Découvrir les produits

Abonnements

oc-projet8-dbt

Dernière mise à jour à 11 avril 2026, 17:53 (UTC+2:00)

Actions

Créer avec le mode Express

Aperçu du cluster

ARN
arn:aws:ecs:eu-west-3:697908643602:cluster/oc-projet8-dbt

Statut
Actif

Surveillance CloudWatch
Valeur par défaut

Instances de conteneur enregistrées
-

Services

Drainage
-

Actif

Tâches

En attente
-

En cours d'exécution
-

Services

Démons

Nouveau

Tâches

Infrastructure

Métriques

Tâches planifiées

Configuration

Historique de l'événement

Balises

Fournisseurs de capacité (2)

Dernière mise à jour à 11 avril 2026, 17:52 (UTC+2:00)

Gérer les identifications

Mettre à jour

Supprimer

Créer

Filtrer les fournisseurs de capacité par propriété ou valeur

Fournisseur de capacité	Type de mise à l'échelle	Modèle de mise en service	Mettre à jour le statut	Raison de la mise à jour du ...
Fargate	Fargate	-	-	-
Spot Fargate	Spot Fargate	-	-	-

Fonctionnement du cluster

- ECS orchestre l'exécution
- Fargate lance le conteneur sans gérer de serveur
- Le conteneur exécute dbt run puis dbt test
- Les tables finales sont créées dans RDS
- Les logs sont envoyés vers CloudWatch

Automatisation et observabilité AWS


EventBridge
scheduler



ECS Runtask
Fargate



CloudWatch
Logs



Amazon EventBridge – Automatisation DBT

Amazon EventBridge

Tableau de bord

Ressources pour développeurs

Apprendre

Environnement de test (sandbox)

Quick Starts

Bus

Bus d'événements

Règles

Points de terminaison globaux

Archives

Relectures

Pipelines

Pipelines

Planificateur

Planifications

Groupes de planifications

Planifications

Amazon EventBridge

Planifications

dbt-projet8-schedule

Activer

Modifier

Supprimer

dbt-projet8-schedule

Détails de la planification

Nom de la planification

dbt-projet8-schedule

Description

-

Nom du groupe de planifications

default

Statut

⏸ Désactivé

ARN de planification

arn:aws:scheduler:eu-west-3:697908643602:schedule/default/dbt-projet8-schedule

Action après l'achèvement

NONE

Heure de début de la planification

-

Heure de fin de la planification

-

Fuseau horaire d'exécution

Europe/Paris

Fenêtre horaire flexible

-

Date de création

Apr 07, 2026, 18:57:31 (UTC+02:00)

Date de dernière modification

Apr 07, 2026, 20:35:56 (UTC+02:00)

Planification

Cible

Politique de nouvelles tentatives

File d'attente de lettres mortes

Chiffrement

Planification

Fréquence fixe [Infos](#)

rate (5 minutes)

Heure de début de la planification

-

Planification

- Fréquence fixe
- Période (dev): 5 minute
- Période (prod): 1 jour

Cible

- Cluster ECS

Amazon CloudWatch – Journaux

CloudWatch

Favoris et récents

Ingestion

Tableaux de bord

Alarmes 0 0 0

GenAI Observability

Vigie applicative (APM)

Surveillance de l'infrastructure

Journaux

Gestion des journaux

Log Analytics Aperçu

Anomalies dans les journaux

Queue en direct

Logs Insights

Contributor Insights

/ecs/dbt-projet8

Actions

Consulter dans Logs Insights

Démarrer le suivi

Rechercher un groupe de journaux

Informations de groupe de journaux

Flux de journaux

Balises

Protection des données

Détection des anomalies

Filtres de métriques

Filtres d'abonnement

Contributor Insights

Flux de journaux (11)

Par défaut, nous chargeons uniquement les flux de journaux les plus récents.

Filter les flux de journaux ou essayer la recherche de préfixe

Correspondance exacte

Afficher les résultats expirés

Informations

1

Flux de journaux

Heure du dernier événement

ecs/dbt-runner/c2a9f60206974c8a98be56fb9339e2590

2026-04-07 18:33:39 (UTC)

ecs/dbt-runner/cd84909015194d7c82ca28f08a97fd08

2026-04-07 18:28:37 (UTC)

ecs/dbt-runner/5abb3e0ca88948a99747feb3ce365971

2026-04-07 18:23:37 (UTC)

ecs/dbt-runner/0dba4fff975645909737ed49557e4e75

2026-04-07 18:18:55 (UTC)

ecs/dbt-runner/c5a96ea245c8420bb873f0cf8be0ffc9

2026-04-07 18:03:22 (UTC)


Flux de journaux Chaque invocation du conteneur par ECS est tracée.

	Horodatage	Message
▶	2026-04-07T18:33:27.696Z	[0m18:33:27 1 of 8 START sql view model staging.stg_infoclimat_observations [RUN]
▶	2026-04-07T18:33:27.963Z	[0m18:33:27 1 of 8 OK created sql view model staging.stg_infoclimat_observations [[32mCREATE VIEW[0m in 0.26s]
▶	2026-04-07T18:33:27.965Z	[0m18:33:27 2 of 8 START sql view model staging.stg_infoclimat_stations [RUN]
▶	2026-04-07T18:33:28.065Z	[0m18:33:28 2 of 8 OK created sql view model staging.stg_infoclimat_stations [[32mCREATE VIEW[0m in 0.10s]

Événements de journaux

Le détail de chaque invocation est disponible.

Amazon CloudWatch – Métriques



Métriques RDS

- CPUUtilization > % d'utilisation CPU de la base
- DatabaseConnections > nombre de connexions actives

Questions

